

UP1 – Majeure Science des Données 2025-2026

Probabilités Avancées


Chapitre I : Vecteurs Gaussiens (VGs)

Chapitre II : Lois conditionnelles

☞ **chapitre 1 au cœur de la statistique classique (Régression Linéaire, Séries Temporelles, ...)**

☞ **chapitre 2 indispensable pour bien comprendre les problématiques de prédiction (régression, classification supervisée, ...) ou de prévision**

Motivation pour l'étude des VGs : Régression Linéaire Multiple (RLM)



👉 **objectif** : prédire le rendement d'une parcelle de blé juste avant récolte...

On devine une relation de la forme (droite en rouge)

$$\text{rendement} = \beta_0 + \beta_1 \times \text{pluie} + \text{Erreur}$$

☛ modèle de **régression linéaire simple (RLS)** de la forme $y = \beta_0 + \beta_1 x + \varepsilon$ avec $p = 1$
prédicteur : $x = \text{pluie}$

ou d'une forme « plus complexe »

$$\text{rendement} = \beta_0 + \beta_1 \times \text{pluie} + \beta_2 \times \text{pluie}^2 + \text{Erreur}$$

☛ modèle de **régression linéaire multiple** de la forme $y = \beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)} + \varepsilon$ avec
 $p = 2$ prédicteurs : $x^{(1)} = \text{pluie}$ et $x^{(2)} = \text{pluie}^2$

☛ la variable x est **aléatoire** ou **non contrôlée**. Même dans le cas où ce prédicteur serait **contrôlé**, la réponse $y = \text{« rendement »}$ serait aléatoire compte tenu du terme d'**Erreur**, composante résiduelle qui intègre tous les autres facteurs (aléatoires ou non) influençant le rendement...

Modèle général de régression linéaire multiple (décliné sur la population des n individus) :

$$1 \leq i \leq n, \quad y_i = \beta_0 + \beta_1 x_i^{(1)} + \dots + \beta_p x_i^{(p)} + \varepsilon_i \quad \text{où } \varepsilon_i \text{ résidu (théorique)}$$

Sous forme matricielle : $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$

- $\mathbf{y} = (y_1 \dots y_n)^T$ vecteur colonne des réponses de taille n
- \mathbf{X} matrice de taille $n \times (p+1)$
- $\boldsymbol{\beta} = (\beta_0 \dots \beta_p)^T$ de taille $(p+1)$: paramètres pour la **réponse espérée**
- $\boldsymbol{\varepsilon} = (\varepsilon_1 \dots \varepsilon_n)^T$ vecteur colonne des **résidus théoriques** ou **erreurs** de régression (**bruit**)

Hypothèses par défaut des logiciels de Statistique ou de « data science » :

$\varepsilon_1, \dots, \varepsilon_n$ réalisations de **variables aléatoires indépendantes de même loi** supposée normale $N(0, \sigma^2)$ de densité :

$$x \rightarrow \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{x^2}{2\sigma^2}\right)$$

☹ **Une difficulté : $\varepsilon_1, \dots, \varepsilon_n$ ne sont pas observés directement !**

Toute l'analyse et compréhension du modèle repose sur le fait que le vecteur

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \in \mathbb{R}^n$$

est un **vecteur aléatoire de loi gaussienne n-dimensionnelle**

☛ **\mathbf{Y} est appelé vecteur gaussien (VG)**

```
> summary(lm(rend ~ pluie + pluie2))
```

Residuals:

Min	1Q	Median	3Q	Max
-0.125759	-0.031894	-0.000287	0.035384	0.093880

Coefficients:


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.04246	0.04512	-0.941	0.35109
pluie	2.50171	0.31868	7.850	2.49e-10 ***
pluie2	-1.52278	0.54701	-2.784	0.00752 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04893 on 51 degrees of freedom

Multiple R-squared: 0.914, Adjusted R-squared: 0.9106

F-statistic: 271 on 2 and 51 DF, p-value: < 2.2e-16



👉 le calcul des probabilités et la Statistique sont au cœur de la science des données
👉 tous ces résultats résultent des propriétés fondamentales des vecteurs gaussiens et du TCL multi-dimensionnel !

I.1. Loi gaussienne sur \mathbb{R}

X v.a.r. est dite de loi *normale* (ou *gaussienne*) de *moyenne* $\mu \in \mathbb{R}$ et de *variance* $\sigma^2 > 0$ (*écart-type* $\sigma > 0$) si sa *loi de probabilité* admet la *densité* suivante :

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Ainsi,


$$P(X \in [a, b]) = \int_a^b f_X(x) dx$$

On notera $X \sim N(\mu, \sigma^2)$.


Convention. $X = \mu$ est gaussienne dégénérée, i.e. $X \sim N(\mu, 0)$.

Propriété : $X = \mu + \sigma Z$ où Z est de loi normale $N(0, 1)$, soit la loi normale dite centrée-réduite

I.1. Loi gaussienne sur \mathbb{R}



I.1. Loi gaussienne sur \mathbb{R}



I.1. Loi gaussienne sur \mathbb{R}

Importance de la loi normale – Théorème Central Limite (TCL):

X_1, X_2, \dots indépendantes et identiquement distribuées (en abrégé i.i.d.) de moyenne μ et de variance σ^2

Considérons la suite des sommes partielles : $S_n = X_1 + \dots + X_n$ ($n \geq 1$).

Alors, pour tout $a < b$:


$$P\left(a \leq \frac{\sqrt{n}}{\sigma} \times \left(\frac{S_n}{n} - \mu\right) \leq b\right) = P\left(a \leq \frac{S_n - n\mu}{\sigma\sqrt{n}} \leq b\right) \rightarrow_n \int_a^b \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx$$

En pratique : $\frac{S_n}{n} \approx_{n \text{ grand}} N\left(\mu, \frac{\sigma^2}{n}\right) \Leftrightarrow S_n \approx_{n \text{ grand}} N(n\mu, n\sigma^2)$

Si les X_k sont $N(\mu, \sigma^2)$, alors $\frac{S_n}{n}$ est de loi $N\left(\mu, \frac{\sigma^2}{n}\right)$ et S_n est de loi $N(n\mu, n\sigma^2)$.

I.1. Loi gaussienne sur \mathbb{R}

Loi binomiale $B(n=12, p=0.5)$ et loi normale $N(np, np(1-p))$



I.2. Vecteurs gaussiens (VGs)

Définition. $X = (X_1, \dots, X_d) \in \mathbb{R}^d$ où X_1, \dots, X_d sont des v.a. est appelé **vecteur aléatoire réel** (V.a.r.) de dimension d (ou V.a.r. d -dimensionnel).

Définition (V.a. continu). $X = (X_1, \dots, X_d) \in \mathbb{R}^d$ est dit **continu** de densité :

$$\mathbf{x} = (x_1, \dots, x_d) \in \mathbb{R}^d \rightarrow f_X(\mathbf{x})$$

si (par définition)



$$P(X \in [a_1, b_1] \times \dots \times [a_d, b_d]) = \int_{[[a, b]]} f_X(\mathbf{x}) d\mathbf{x}$$

où $[[a, b]]$ désigne un hyper-rectangle quelconque $[a_1, b_1] \times \dots \times [a_d, b_d]$ de \mathbb{R}^d .

Remarque : $f_X \geq 0$ et $\int_{\mathbb{R}^d} f_X(\mathbf{x}) d\mathbf{x} = 1$

I.2. Vecteurs gaussiens (VGs)

Intégrale multiple (comme limite de sommes de Riemann)




Cas particulier : si $f(x) = f_1(x_1) \times \dots \times f_d(x_d)$, alors :

$$\int_{[[a, b]]} \mathbf{f}(\mathbf{x}) d\mathbf{x} = \int_{a_1}^{b_1} f_1(x_1) dx_1 \times \dots \times \int_{a_d}^{b_d} f_d(x_d) dx_d$$

I.2. Vecteurs gaussiens (VGs)

Exemple simple : $X = (X_1, X_2)$ où X_1, X_2 sont i.i.d. de loi $N(0, 1)$, alors X admet la densité de probabilité suivante :

$$x = (x_1, x_2) \rightarrow \frac{1}{2\pi} \exp\left(-\frac{\|x\|^2}{2}\right)$$



👉 cloche de Gauss bidimensionnelle

I.2. Vecteurs gaussiens (VGs)

Lois marginales d'un V.a.r. : ce sont les lois des composantes X_1, \dots, X_d .

Dans le **cas continu**, ces composantes admettent des densités f_{X_1}, \dots, f_{X_d} données par

$$f_{X_1}(x_1) = \int_{\mathbb{R}^{d-1}} f_X(x_1, \dots, x_d) dx_2 \times \dots \times dx_d, \text{ etc.}$$

Cas indépendance : $X = X = (X_1, \dots, X_d)$ V.a. **continu** alors

$$X_1, \dots, X_d \text{ indépendantes} \Leftrightarrow f_X(x) = f_{X_1}(x_1) \times \dots \times f_{X_d}(x_d)$$

I.2. Vecteurs gaussiens (VGs)

Définition – moyenne et matrice de (variance-)covariance d'un V.a.r. X d-dimensionnel :

- $\mu = (EX_1, \dots, EX_d) \in \mathbb{R}^d$ **moyenne de X : $\mu = E(X)$**
- $\Gamma = (E[(X_i - \mu_i)(X_j - \mu_j)])_{i,j}$ matrice de taille $d \times d$ appelée **covariance de X : $\Gamma = \text{Cov}(X)$** (matrice des variances-covariances du vecteur X)

Convention usuelle : tout vecteur de \mathbb{R}^d est vu comme un vecteur colonne de taille d (matrice de taille $d \times 1$).

Moyenne d'une matrice aléatoire : $E(M) = (EM_{i,j})$

Ainsi, en langage matriciel, $\mu = E(X)$ et $\Gamma = E[(X - \mu)(X - \mu)^T]$

I.2. Vecteurs gaussiens (VGs)

Propriété 1. La matrice Γ de terme général $\Gamma_{ij} = \text{Cov}(\mathbf{X}_i, \mathbf{X}_j)$ est une matrice **symétrique positive**. Sa diagonale est formée des variances individuelles des variables : $\Gamma_{ii} = \text{Cov}(\mathbf{X}_i, \mathbf{X}_i) = \text{Var}(\mathbf{X}_i)$.

Propriété 2. Si A est une application linéaire de \mathbb{R}^d dans \mathbb{R}^d (identifiée à une matrice $d \times d$) et \mathbf{b} un vecteur de \mathbb{R}^d , le vecteur aléatoire $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ vérifie

$$\mu_{\mathbf{Y}} = \mathbf{A}\mu_{\mathbf{X}} + \mathbf{b} \text{ et } \Gamma_{\mathbf{Y}} = \mathbf{A}\Gamma_{\mathbf{X}}\mathbf{A}^T$$

où $\mu_{\mathbf{Y}} = E(\mathbf{Y})$ et $\Gamma_{\mathbf{Y}} = \text{Cov}(\mathbf{Y})$ (se généralise à A matrice rectangulaire).

Propriété 3. Si $\Gamma = \text{Cov}(\mathbf{X})$ est de rang r , alors $\mathbf{X} \in \text{Im}(\Gamma)$ sous-espace vectoriel de dimension r . Dit autrement, \mathbf{X} a seulement **r degrés de liberté**. Si donc $r < d$, \mathbf{X} n'admet pas de densité définie sur \mathbb{R}^d .

I.2. Vecteurs gaussiens (VGs)

Définition d'un Vecteur Gaussien (VG) : soit $\mu \in \mathbb{R}^d$ et Γ une matrice symétrique définie positive de taille $d \times d$ (le rang de Γ est d). Un vecteur aléatoire réel $X = (X_1, \dots, X_d) \in \mathbb{R}^d$ est dit **gaussien** (ou multi-gaussien) de moyenne μ et de covariance Γ s'il admet la densité dite (multi-)gaussienne ou normale suivante :

$$x \rightarrow \frac{1}{\sqrt{\det(\Gamma)} \sqrt{2\pi}^d} \exp\left(-\frac{1}{2} \langle x - \mu | \Gamma^{-1}(x - \mu) \rangle\right)$$



Cette expression définit bien une densité associée à un vecteur aléatoire de moyenne μ et de covariance Γ et on a la décomposition $\mathbf{X} = \mu + \mathbf{U}\Sigma\mathbf{Z}$ avec les variables $\mathbf{Z}_1, \dots, \mathbf{Z}_d$ **i.i.d.** $\mathbf{N}(0, 1)$ et où les matrices Σ et \mathbf{U} sont obtenues par diagonalisation en base orthonormée de la matrice de covariance :

$$\Gamma = \mathbf{U}\Lambda\mathbf{U}^T = \mathbf{U}\Sigma^2\mathbf{U}^T \quad (\Sigma = \sqrt{\Lambda}) \text{ avec } \mathbf{U}^T\mathbf{U} = \mathbf{I}_d$$

On notera $\mathbf{N}(\mu, \Gamma)$ la loi normale multivariée de moyenne μ et de covariance Γ .


I.2. Vecteurs gaussiens (VGs)

Exemples



$\mu = 0$; $\text{Var}(X) = \text{Var}(Y) = 1$; $\rho = 0$ (à gauche) et $\rho = 0.8$ (à droite)

I.2. Vecteurs gaussiens (VGs)



Courbes d'iso-densité du cas $\rho = 0.8$

I.2. Vecteurs gaussiens (VGs)

Théorème Central Limite multidimensionnel

Soit $X^{(1)}, X^{(2)}, \dots$ une suite de vecteurs aléatoires **indépendants et identiquement distribués** dans \mathbb{R}^d de vecteur moyenne μ et de matrice de covariance Γ supposée **inversible**. Pour $n \geq 1$, on note encore $S_n = X^{(1)} + \dots + X^{(n)} \in \mathbb{R}^d$.

Alors, pour tout hyper-rectangle $[[a, b]]$ de \mathbb{R}^d


$$\mathbf{P}(\sqrt{n} \times (\frac{S_n}{n} - \mu) = \frac{1}{\sqrt{n}} \times (S_n - n\mu) \in [[a, b]]) \rightarrow_n \int_{[[a, b]]} \mathbf{f}_X(x) dx$$

où f est la densité de la loi gaussienne multivariée $N(0, \Gamma)$.

En pratique : $\frac{S_n}{n} \approx N(\mu, \frac{1}{n} \Gamma)$

I.2. Vecteurs gaussiens (VGs)

Loi trinominale (bâtons) et approximation gaussienne (surface)



Paramètres de la loi trinominale :

$$n = 20$$

$$p_1 = 0.3$$

$$p_2 = 0.5$$

(et donc $p_0 = 0.2$)

I.3. Vecteur gaussien centré-réduit

Définition. X est dit *gaussien centré-réduit* si $\mathbf{X} \sim \mathbf{N}(\mathbf{0}, \mathbf{I}_d)$ où \mathbf{I}_d désigne la matrice *identité* de taille d . Ses **composantes** X_1, \dots, X_d sont **indépendantes et de loi $\mathbf{N}(0, 1)$** . Sa densité est :

$$\mathbf{x} = (x_1, \dots, x_d)^T \rightarrow \frac{1}{\sqrt{2\pi}^d} \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right)$$


où $\|\mathbf{x}\| = \sqrt{x_1^2 + \dots + x_d^2}$ désigne la norme euclidienne usuelle de \mathbb{R}^d .

Interprétation. Les composantes du vecteur \mathbf{X} forment un bruit « blanc », ce qui renvoie aussi à la terminologie de **bruit blanc gaussien** (standard).

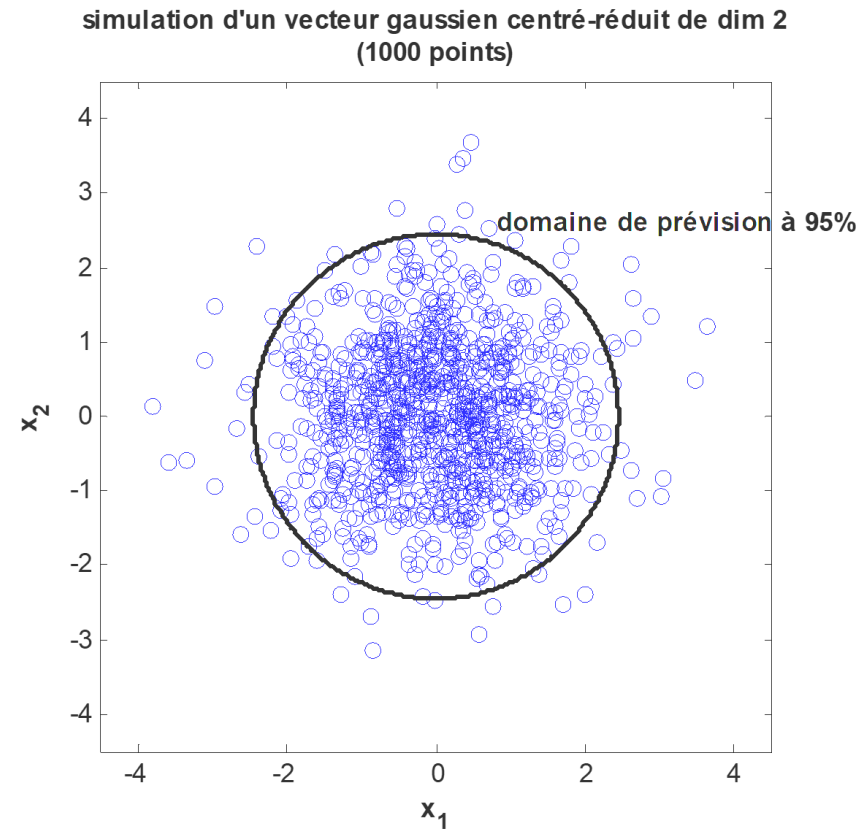
Dans toute la suite, ε désignera un vecteur aléatoire de loi $\mathbf{N}(\mathbf{0}, \mathbf{I}_d)$.

I.3. Vecteur gaussien centré-réduit

Cas de la dimension $d = 2$:



I.3. Vecteur gaussien centré-réduit



I.3. Vecteur gaussien centré-réduit

Propriété fondamentale de ε gaussien centré-réduit :

Soit U une **isométrie** (linéaire) : $U^T U = I_d$.

- $\varepsilon \sim N(0, I_d) \Rightarrow U\varepsilon \sim N(0, I_d)$
- $Z = U^T \varepsilon$ coordonnées (euclidiennes) du vecteur ε dans la base orthonormée associée aux vecteurs colonne u_1, \dots, u_d de la matrice U , alors :

$$\varepsilon = Z_1 u_1 + \dots + Z_d u_d$$

avec les (nouvelles) variables $Z_1 + \dots + Z_d$ i.i.d. $N(0, 1)$

I.3. Vecteur gaussien centré-réduit

THÉORÈME DE COCHRAN*

Soit P un projecteur orthogonal, i.e. $P^2 = P$ et $P^T = P$. Alors :

- les vecteurs aléatoires $P\varepsilon$ et $(I - P)\varepsilon$ sont **indépendants**, de degrés de liberté p et $d - p$ où $p = \dim(\text{Im}P)$.
- Les variables aléatoires $\|P\varepsilon\|^2$ et $\|(I - P)\varepsilon\|^2$ sont **indépendantes** de lois respectives

$$\|P\varepsilon\|^2 \sim \chi_p^2 \text{ et } \|(I - P)\varepsilon\|^2 \sim \chi_{d-p}^2$$

(*William Gemmel Cochran, 1909-1980)

I.4. Vecteurs gaussiens quelconques

Définition générale d'un vecteur gaussien

Un vecteur aléatoire $X = (X_1, \dots, X_p) \in \mathbb{R}^p$ est dit **gaussien** s'il existe $\mu \in \mathbb{R}^p$, une matrice A de taille $p \times q$ et $\varepsilon \sim N(0, I_q)$ tels que

$$X = \mu + A\varepsilon$$

X image par une **transformation affine** de \mathbb{R}^q dans \mathbb{R}^p d'un VG centré-réduit de dimension q .

Moyenne et matrice de covariance :

$$E(X) = \mu$$

$$\text{Cov}(X) = AA^T$$

I.4. Vecteurs gaussiens quelconques

Densité et décomposition de Prasanta Mahalanobis (1893-1972)

- $\Gamma = \text{Cov}(X) = AA^T$ est **inversible**, alors X admet la densité

$$x \rightarrow \frac{1}{\sqrt{\det(\Gamma)} \sqrt{2\pi}^p} \exp\left(-\frac{1}{2} \langle x - \mu, \Gamma^{-1}(x - \mu) \rangle\right)$$

et

$$X = \mu + \sqrt{\lambda_1} Z_1 U_1 + \dots + \sqrt{\lambda_p} Z_p U_p ; Z \sim N(0, I_p)$$

en écrivant que $\Gamma = U\Lambda U^T$ où $U^T U = I_p$ et $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$ les valeurs propres de Γ .

- Γ est **non inversible**, X est dit « dégénéré » et « vit » en réalité dans un sous-espace affine de dimension $d < p$ (et $d \leq q$). De manière plus précise, on a

$$X = \mu + \sqrt{\lambda_1} Z_1 U_1 + \dots + \sqrt{\lambda_d} Z_d U_d ; Z \sim N(0, I_d)$$

Dans les deux cas, on dira que X est de loi $N(\mu, \Gamma)$.

I.4. Vecteurs gaussiens quelconques

CAS DE L'INDÉPENDANCE. ☺

Si $X \in \mathbb{R}^d$ est un vecteur gaussien, alors

$$\begin{aligned} X_1, \dots, X_d \text{ indépendantes} &\Leftrightarrow \text{Cov}(X_i, X_j) = 0 \text{ pour } i \neq j \\ &\Leftrightarrow \Gamma \text{ matrice diagonale} \end{aligned}$$

SIMULATION DE $X \sim N(\mu, \Gamma)$.

- Faire la décomposition de Cholesky de Γ : $\Gamma = SS^T$ avec S triangulaire inférieure (et diagonale positive)
- Simuler $\varepsilon \sim N(0, I_d)$
- Calculer $X = \mu + S\varepsilon$

I.4. Vecteurs gaussiens quelconques

Quelques propriétés à retenir pour la pratique :

- $X = \mu + A\varepsilon$ avec $\varepsilon \sim N(0, I_q)$ est un VG : $X \sim N(\mu, AA^T)$
- toute transformation affine d'un VG est un VG. En particulier, les composantes d'un VG sont toutes de loi normale sur \mathbb{R}
- si $X = (X_1, \dots, X_p)$ est un VG de loi $N(\mu, \Gamma)$ et u un vecteur de \mathbb{R}^p , alors
 $u^T X = u_1 X_1 + \dots + u_p X_p$ est de variance $u^T \Gamma u$, donc de loi $N(u^T \mu, u^T \Gamma u)$
- indépendance = non corrélation dans le cas gaussien

Annexe DVS

Décomposition en valeurs singulières (DVS ou SVD):

A étant donnée de taille $p \times q$, il existe une matrice $p \times q$ Σ diagonale à termes diagonaux ≥ 0 telle que

$$\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T \quad \text{avec} \quad \mathbf{V}^T\mathbf{V} = \mathbf{I}_q \text{ et } \mathbf{U}^T\mathbf{U} = \mathbf{I}_p$$

Ainsi, $\mathbf{\Gamma} = \mathbf{A}\mathbf{A}^T = \mathbf{U}\mathbf{\Lambda}_p\mathbf{U}^T$ avec $\mathbf{\Lambda}_p = \Sigma\Sigma^T$ diagonale $p \times p$

$$\mathbf{A}^T\mathbf{A} = \mathbf{V}\mathbf{\Lambda}_q\mathbf{V}^T \quad \text{avec } \mathbf{\Lambda}_q = \Sigma^T\Sigma \text{ diagonale } q \times q$$

Les termes diagonaux de Σ sont appelés *valeurs singulières* de la matrice A et sont le plus souvent rangées par ordre décroissant.

II.1. Lois conditionnelles dans le cas discret

Soient Y v.a.r. et X v.a. **discrète** $X \in \{x_1, x_2, \dots, x_p\}$.

On appelle *loi conditionnelle de Y sachant $X = x_k$* la loi de probabilité notée $\mathbf{P}_{Y|X=x_k}$ définie par

$$\mathbf{P}_{Y|X=x_k}([a, b]) = \mathbf{P}(Y \in [a, b] \mid X = x_k) = \frac{\mathbf{P}(Y \in [a, b] \text{ et } X = x_k)}{\mathbf{P}(X = x_k)}$$

L'ensemble des p lois de probabilité $\mathbf{P}_{Y|X=x_k}$ ($1 \leq k \leq p$) est appelé *système des lois conditionnelles de Y sachant X* .

Exemple 1. Loi du pile ou face deux fois : Y = nombre total de pile, X résultat du premier lancer

II.1. Lois conditionnelles dans le cas discret

Cas où Y est également discrète : $Y \in \{y_1, y_2, \dots, y_q\}$

les p lois conditionnelles de Y sachant X s'écrivent

$$P_{Y|X=x_i} = \sum_{j=1}^q p_{j|i} \delta_{y_j} \text{ où } p_{j|i} = \frac{p_{ij}}{p_{i.}} = \frac{P(Y = y_j \text{ et } X = x_i)}{P(X = x_i)}$$

On a (!)

X, Y indépendantes $\Leftrightarrow P_{Y|X=x_i} = P_Y$ pour tout i

$$\Leftrightarrow p_{j|i} = \frac{P(Y = y_j \text{ et } X = x_i)}{P(X = x_i)} = P(Y = y_j) = p_{.j}$$

II.2. Lois conditionnelles dans le cas continu

$(X, Y) \in \mathbb{R}^2$ est un vecteur continu de densité $(x, y) \rightarrow f_{(X, Y)}(x, y)$


La loi conditionnelle de Y sachant $X = x$ est définie par la *densité conditionnelle* suivante

$$f_{Y | X = x}(y) = \frac{f_{(X, Y)}(x, y)}{f_X(x)}$$

pour tout x tel que $f_X(x) = \int_{-\infty}^{+\infty} f_{(X, Y)}(x, y) dy \neq 0$.

II.2. Lois conditionnelles dans le cas continu

Densité loi normale bivariée ($r=0.6$)



II.2. Lois conditionnelles dans le cas continu

Exemple 2. $Y = X + \varepsilon$ où $X \sim N(\mu_X, \sigma_X^2)$ et $\varepsilon \sim N(0, \sigma^2)$ sont indépendantes

$$X, Y \text{ indépendantes} \Leftrightarrow P_{Y|X=x} = P_Y \Leftrightarrow f_{Y|X=x}(y) = \frac{f_{(X,Y)}(x,y)}{f_X(x)} = f_Y(y)$$

FORMULE DE BAYES.

$$f_{X|Y=y}(x) = \frac{f_{Y|X=x}(y) \times f_X(x)}{f_Y(y)}$$

sachant que $f_Y(y) = \int_{-\infty}^{+\infty} f_{Y|X=x}(y) \times f_X(x) dx$ est simplement une constante de normalisation.

II.3. Espérance conditionnelle

On a vu que l'information apportée par $X = (X_1, \dots, X_p)$ modifie (si non indépendance) les probabilités que l'on a sur les valeurs prises par Y avec la notion de loi conditionnelle.

Il est tout autant naturel de se demander en quoi la connaissance des variables X_1, \dots, X_p réduit ou non l'incertitude que l'on a sur Y si l'on mesure cette incertitude en terme de dispersion usuelle, i.e. de variance.

😊😊😊 On introduit pour cela l'espace vectoriel $L^2(P)$ des v.a. admettant une variance et muni du produit scalaire suivant :


$$\langle U | V \rangle = E(UV)$$

II.3. Espérance conditionnelle

Définition de l'espérance conditionnelle $E(Y | X)$:

$E(Y | X)$ est la **projection orthogonale** de Y sur le sous-espace $L^2(X)$ de $L^2(P)$ défini par

$$L^2(X) = \{ Z = \varphi(X) \in L^2(P) \text{ avec } \varphi : \mathbb{R}^p \rightarrow \mathbb{R} \}.$$



Bien noter que $E(Y | X)$ est une variable aléatoire!

II.3. Espérance conditionnelle

Formules de l'espérance totale et de la variance totale

$$Y = E(Y | X) + \varepsilon \quad \text{avec} \quad E(\varepsilon) = 0 \text{ et :}$$

$$\text{Cov}(\varepsilon, \varphi(X)) = \langle \varepsilon, \varphi(X) \rangle = 0 \text{ si } \varphi(X) \in L^2(X)$$

En particulier : $E(E(Y | X)) = E(Y)$ et $\text{Var}(Y) = \text{Var}(E(Y | X)) + \text{Var}(\varepsilon)$

Dans cette décomposition, ε est de variance minimale : on ne peut pas réduire plus la variance résiduelle!

Définition. On définit le pourcentage de la variance de Y expliquée par X selon

$$\% \text{ de variance expliquée} = 100 \times \frac{\text{Var}(E(Y | X))}{\text{Var}(Y)} \%$$

$$\% \text{ de variance non expliquée ou résiduelle} = 100 \times \frac{\text{Var}(\varepsilon)}{\text{Var}(Y)} \%$$

II.3. Espérance conditionnelle

Espérance conditionnelle comme moyenne de la loi conditionnelle. On a simplement

$$E(Y | X) = m(X)$$

où la fonction m vérifie

$$m(x) = \int_{-\infty}^{+\infty} y \times f_{Y|X=x}(y) dy = E(Y | X = x)$$

i.e. $m(x)$ est la moyenne de la loi conditionnelle de Y sachant $X = x$.

De plus, on a **la formule de transfert conditionnel**

$$E(f(Y) | X) = \varphi(X) \text{ où } \varphi \text{ se calcule selon } \varphi(x) = \int f(y) f_{Y|X=x}(y) dy$$

II.3. Espérance conditionnelle

Exercice 7. Soit (X, Y) un vecteur gaussien bidimensionnel. On note $E_L(Y | X)$ la projection orthogonale de Y sur $F = \text{ev}\{1, X\} := \{\beta_0 + \beta_1 X : \beta_0, \beta_1 \text{ scalaires}\}$.

On dit encore que $E_L(Y | X)$ est la **régression linéaire** de Y sur X .

1. Calculer $E_L(Y | X)$.


2. On considère la décomposition orthogonale $Y = E_L(Y | X) + \varepsilon$ où donc

$$\varepsilon = Y - E_L(Y | X).$$

Montrer que X et ε sont non corrélées puis indépendantes.

3. En déduire les lois conditionnelles de Y sachant $X = x$ pour tout x réel et illustrer le résultat obtenu dans le plan $0xy$ en faisant apparaître les courbes d'isodensité du vecteur gaussien (X, Y) .

II.3. Espérance conditionnelle



II.3. Espérance conditionnelle

On généralise l'exercice précédent :

Si $(X, Y) = (X_1, \dots, X_p, Y)$ est un vecteur gaussien, alors :

- $E(Y | X) = E_L(Y | X)$ est une **fonction linéaire (affine)** des X_k
- Le résidu ε est **indépendant** des X_k et de loi $N(0, \text{Var}(\varepsilon))$ où

$$\text{Var}(\varepsilon) = \text{Var}(Y) - \text{Var}(E(Y | X))$$

- La loi conditionnelle de Y sachant $X = x$ est gaussienne de variance indépendante de x et égale à la variance du résidu ε