

Éléments complémentaires pour l'AFC

A partir : réduction dimension

- *Proximités entre profils : analyse par rapport l'origine mais possible à partir des centres de gravité*
- *Dans espace R^p avec analyse par rapport à l'origine : réduction de dimension*
- *Critère de projection orthogonale selon un axe où inertie maximale (variance) passant par O et engendré par un vecteur unitaire u et de métrique D_p*

Avec les :

- des matrices F contenant (k_{ij}/k) avec k_{ij} l'effectif d'individus de modalité ij simultanément
- D_n^{-1} : matrice diagonale des $1/\text{marges lignes}$
- D_p^{-1} : matrice diagonales de $1/\text{marges colonnes}$ (métrique M)

Sur le Profil ligne

$$\text{distance du } \chi^2 : d^2(i, i') = \sum_{j=1}^p \frac{1}{f_{.j}} \left(\frac{f_{ij}}{f_{i.}} - \frac{f_{i'j}}{f_{i'.}} \right)^2$$

n points i du nuage des profils lignes dans R^p chaque point i a pour coordonnées :

$$x_{ij} = \frac{1}{\sqrt{f_{.j}}} \frac{f_{ij}}{f_{i.}}$$

Pour la moyenne pour une variable j = moyenne arithmétique pondérée :

$$\bar{x}_j = \sum_i f_{i.} x_{ij} = \sum_i f_{i.} \frac{1}{\sqrt{f_{.j}}} \frac{f_{ij}}{f_{i.}} = \frac{1}{\sqrt{f_{.j}}} f_{.j}$$

D'où

$$\bar{x}_j = \sqrt{f_{.j}}$$

1° La covariance entre deux var X_j et $X_{j'}$ (centrage par rapport a la moyenne)

$$cov(x_j, x_{j'}) = V_{jj'} = \sum_i f_{i.} \left[\left(\frac{1}{\sqrt{f_{.j}}} \frac{f_{ij}}{f_{i.}} - \sqrt{f_{.j}} \right) \left(\frac{1}{\sqrt{f_{.j'}}} \frac{f_{ij'}}{f_{i.}} - \sqrt{f_{.j'}} \right) \right]$$

$$V_{jj'} = \sum_i \frac{f_{ij} f_{ij'}}{\sqrt{f_{.j}} \sqrt{f_{.j'}} f_{i.}} - \sqrt{f_{.j}} \sqrt{f_{.j'}}$$

On peut montrer que pour le p ième vecteur propre , avec V la matrice de cov a diagonaliser et S la matrice d'inertie :

$$\text{On a la relation : } \lambda_p u_p = V u_p = S u_p$$

Ou S est la matrice (p,p) pour l'espace des R_p (dim p des colonnes)

$$\text{Ou chaque terme de } S \text{ est : } s_{jj'} = \sum_i \frac{f_{ij} f_{ij'}}{\sqrt{f_{.j}} \sqrt{f_{.j'}} f_{i.}}$$

Les vecteurs propres de la matrice V sont identiques à ceux de la matrice S : on peut donc diagonaliser l'un ou l'autre des matrices (cas ou on a centré les données avec la matrice de cov)

2° Dans le cadre vu en cours : analyse des proximités entre individus par rapport à l'origine : on recherche l'axe d'inertie max du nuages profils lignes passant par origine O et engendré par un vecteur unitaire u pour une métrique D_p^{-1} .

$$\text{Max} \left\{ \sum_i f_{i.} d^2(i, O) \right\}$$

Soit maximiser la somme des distances au carré de $O m_i$

Soit rendre max la quantité

$$\mathbf{u}' \mathbf{D}^{-1}_p \mathbf{F}' \mathbf{D}^{-1}_n \mathbf{F} \mathbf{D}^{-1}_p \mathbf{u}$$

Avec la contrainte $\mathbf{u}' \mathbf{D}^{-1}_p \mathbf{u} = 1$

Alors u est vecteur propre la matrice

$$\mathbf{S} = \mathbf{F}' \mathbf{D}^{-1} \mathbf{n} \mathbf{F} \mathbf{D}^{-1} \mathbf{p} \text{ de terme générale : } s_{jj'} = \sum_{i=1}^n \frac{f_{ij} f_{ij'}}{f_{i.} f_{.j'}}$$

Or \mathbf{S} n'est pas symétrique en générale

Alors :

Si on considère la matrice $\hat{\mathbf{A}} = \mathbf{F}' \mathbf{D}^{-1} \mathbf{n} \mathbf{F}$ elle est symétrique et la matrice diagonale $\mathbf{D}^{-1} \mathbf{p}$

Alors on pose : la matrice $\mathbf{S} = \hat{\mathbf{A}} \mathbf{D}^{-1/2} \mathbf{p} \mathbf{D}^{-1/2} \mathbf{p}$

Pour la solution : partant de la **relation** $\mathbf{S} \mathbf{u} = \lambda \mathbf{u}$

$$\hat{\mathbf{A}} \mathbf{D}^{-1/2} \mathbf{p} \mathbf{D}^{-1/2} \mathbf{p} \mathbf{u} = \lambda \mathbf{u}$$

En pré multipliant par $\mathbf{D}^{-1/2} \mathbf{p}$ et en posant que $\mathbf{D}^{-1/2} \mathbf{p} \mathbf{u} = \mathbf{w}$

$$\mathbf{D}^{-1/2} \mathbf{p} \hat{\mathbf{A}} \mathbf{D}^{-1/2} \mathbf{p} \mathbf{w} = \lambda \mathbf{w}$$

Puis la matrice \mathbf{A} est symétrique :

$$\mathbf{A} = \mathbf{D}^{-1/2} \mathbf{p} \hat{\mathbf{A}} \mathbf{D}^{-1/2} \mathbf{p} = \mathbf{D}^{-1/2} \mathbf{p} \mathbf{F}' \mathbf{D}^{-1} \mathbf{n} \mathbf{F} \mathbf{D}^{-1/2} \mathbf{p}$$

$$\text{Et } \mathbf{A} \mathbf{w} = \lambda \mathbf{w}$$

La matrice \mathbf{A} est diagonalisable et la matrice \mathbf{A} et la matrice \mathbf{S} ont même valeur propre et le passage de \mathbf{w} à \mathbf{u} est donné par :

Le passage du vecteur propre : est donné par $\mathbf{D}^{-1/2} \mathbf{p} \mathbf{u} = \mathbf{w}$

Il est plus facile de diagonaliser la matrice \mathbf{A} avec λ et \mathbf{w} (valeurs propres et vecteurs propres) on peut reconstruire le vecteur \mathbf{u} .

\mathbf{A} est de terme général :

$$a_{jj'} = \sum_{i=1}^n \frac{f_{ij} f_{ij'}}{f_{i.} \sqrt{f_{.j} f_{.j'}}$$

Si on a choisi comme coordonnées des points i , les p quantités :

$$x_{ij} = \frac{1}{\sqrt{f_{.j}}} \frac{f_{ij}}{f_{i.}} (j=1 \dots p)$$

Ce qui permet de diagonaliser une matrice symétrique. La distance du χ^2 devient alors une distance euclidienne classique

$$d^2(i, i') = \sum_{j=1}^p \frac{1}{f_{.j}} \left(\frac{f_{ij}}{\sqrt{f_{i.} \sqrt{f_{.j}}}} - \frac{f_{i'j}}{\sqrt{f_{i'.} \sqrt{f_{.j}}}} \right)^2$$

De centre de gravité $G_j = \sqrt{f_{.j}}$

Quelques éléments sous R : à tester ou à retrouver

```
FF<-profil_ij
#D_n<-diag(nrow(x),nrow(x))/nrow(x) suelement la fréquence f_ij
D_n<-diag(f_i.)
D_n_1<-diag(1/f_i.)
Fprim<-t(FF)
D_p<-diag(f_.j)
D_p_1<-diag(1/f_.j)
FD_n_1<-D_n_1%%FF #
A_at<-Fprim%%D_n_1%%FF
L1<-diag(f_.j^(-1/2))
A<-L1%%A_at%%L1
de<- eigen(A)
svd(A)
```

Puis à vous de *jouer* avec les packages ade4 ou FactoMineR

Compléments sur les formulations de passage nuage des profils ligne et des profils colonnes (octobre 2019)

| Dans R^p profil ligne | Table 1 | Dans R^p profil colonne |
|---|---|---|
| $\mathbf{S} = \mathbf{F}' \mathbf{D}^{-1}_n \mathbf{F} \mathbf{D}^{-1}_p$ | Matrice à diagonaliser | $\mathbf{T} = \mathbf{F} \mathbf{D}^{-1}_p \mathbf{F}' \mathbf{D}^{-1}_n$ |
| $\mathbf{S} \mathbf{u}_\alpha = \lambda_\alpha \mathbf{u}_\alpha$ | Axe factoriel correspondant à la valeur propre λ_α et vecteur propre \mathbf{u}_α | $\mathbf{T} \mathbf{v}_\alpha = \lambda_\alpha \mathbf{v}_\alpha$ |
| $\boldsymbol{\psi}_\alpha = \mathbf{D}^{-1}_n \mathbf{F} \mathbf{D}^{-1}_p \mathbf{u}_\alpha$ | Coordonnées factorielles | $\boldsymbol{\varphi}_\alpha = \mathbf{D}^{-1}_p \mathbf{F}' \mathbf{D}^{-1}_n \mathbf{v}_\alpha$ |
| $\psi_{\alpha i} = \sum_{j=1}^p \frac{f_{ij}}{f_{i.} f_{.j}} u_{\alpha j}$ | Coordonnées factorielles <i>A noter : coordonnées sont centrées et de variance = λ_α</i> | $\varphi_{\alpha j} = \sum_{i=1}^n \frac{f_{ij}}{f_{i.} f_{.j}} v_{\alpha i}$ |

Représentation simultanée par les formules de passage suivantes

Pour passer de l'espace profil ligne à espace profil colonne : vecteurs propres

$$\mathbf{v}_\alpha = \frac{1}{\sqrt{\lambda_\alpha}} \mathbf{F} \mathbf{D}_p^{-1} \mathbf{u}_\alpha$$

$$\mathbf{u}_\alpha = \frac{1}{\sqrt{\lambda_\alpha}} \mathbf{F}' \mathbf{D}_n^{-1} \mathbf{v}_\alpha$$

Avec le table(1) et les deux formules ci-dessus :

$$\boldsymbol{\psi}_\alpha = \sqrt{\lambda_\alpha} \mathbf{D}_n^{-1} \mathbf{v}_\alpha$$

$$\boldsymbol{\varphi}_\alpha = \sqrt{\lambda_\alpha} \mathbf{D}_p^{-1} \mathbf{u}_\alpha$$

Soit explicitement

$$\psi_{\alpha i} = \frac{\sqrt{\lambda_\alpha}}{f_{i.}} v_{\alpha i}$$

$$\varphi_{\alpha j} = \frac{\sqrt{\lambda_\alpha}}{f_{.j}} u_{\alpha j}$$

Remarque :

Nuage des profils-colonne (\mathbb{R}^n) initial: chaque point j de coordonnées $f_{ij}/f_{.j}$ pour $i = 1, \dots, n$; est donc affecté d'une masse $f_{.j}$ les p points sont situés dans un sous espace à $n-1$ dimension puisque $\sum_{i:1}^n \frac{f_{ij}}{f_{.j}} = 1$.