

# Introduction à la Régression à Vaste Marge

(Support Vector Regression — SVR)

**Youssef SALMAN**  
youssef.salman@emse.fr

Ecole des Mines de Saint-Étienne  
*Majeure: Sciences de données*

18 novembre 2025

# Introduction à la SVR

# De la classification à la régression

Dans le chapitre précédent, nous avons étudié les **SVM de classification**, dont l'objectif est de séparer deux classes à l'aide d'un hyperplan de **marge maximale**.

Cependant, dans de nombreuses applications réelles :

- la sortie n'est pas une étiquette  $(+1, -1)$ ,
- mais une **valeur réelle** : prix, température, vitesse, taux, etc.

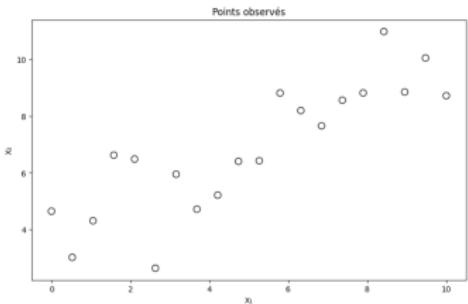
## Limite du SVM classique

Le SVM ne peut pas être appliqué directement lorsque la sortie est un **nombre continu**.

## Objectif du chapitre

Introduire une extension du SVM adaptée à la **régression** : la **Support Vector Regression (SVR)**.

# Introduction



# Introduction

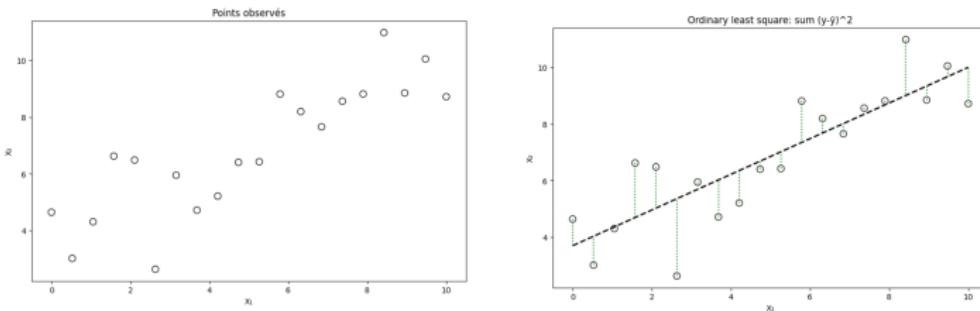


Figure – Idée de la régression linéaire simple

# Introduction

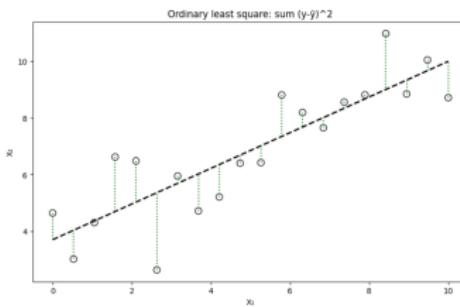
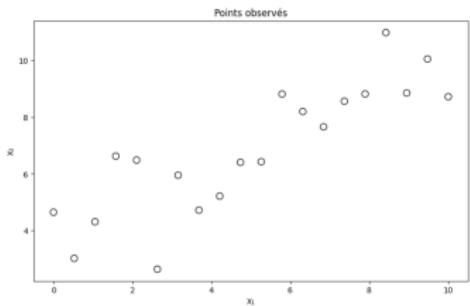
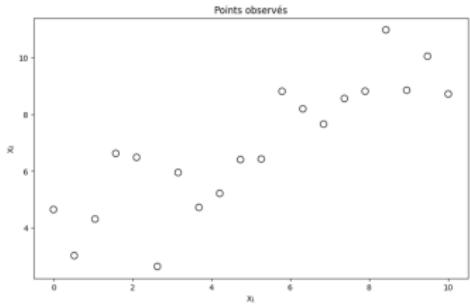


Figure – Idée de la régression linéaire simple



# Introduction

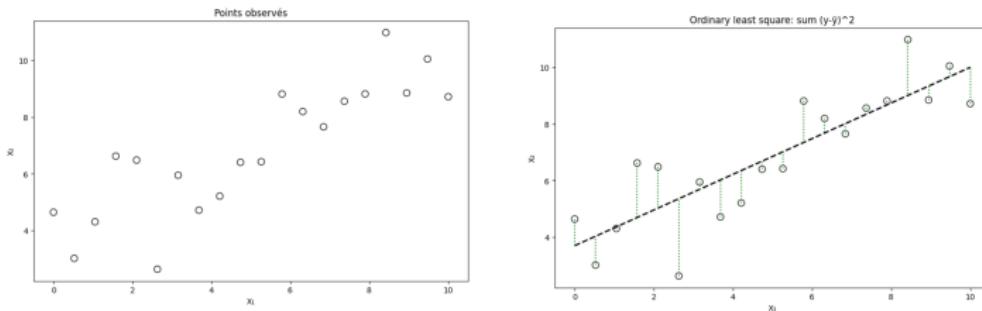


Figure – Idée de la régression linéaire simple

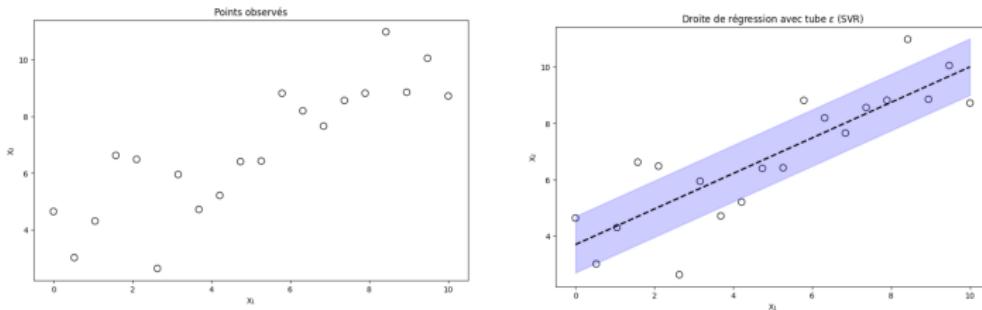
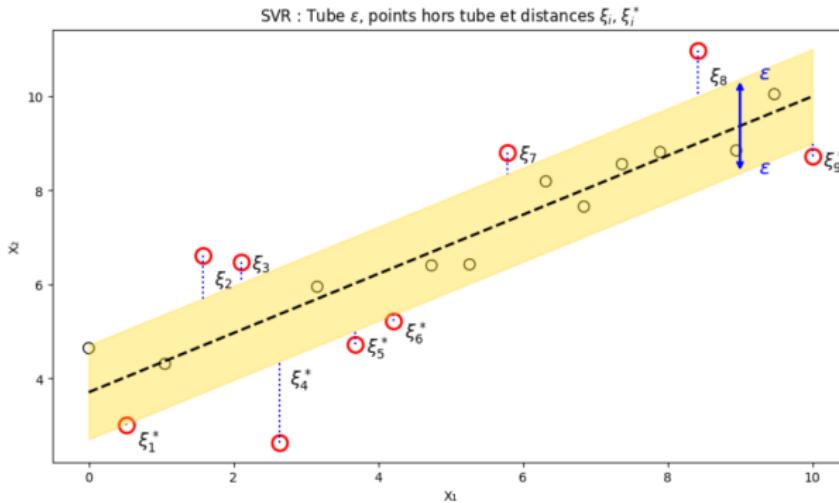


Figure – Idée de la SVR

# Introduction

La SVR tolère l'existence de points **à l'intérieur du tube**, et se concentre principalement sur :

- les points **sur les parois du tube**,
- et les points **à l'extérieur du tube**.



# Problème d'apprentissage supervisé

Nous nous intéressons désormais à un problème **régressif**, où la sortie est une valeur réelle.

- Chaque observation est décrite par un vecteur d'entrée :

$$\mathbf{x} \in \mathbb{R}^d.$$

- L'objectif est de prédire une quantité numérique :

$$y = f(\mathbf{x}) \in \mathbb{R}.$$

## GOAL

*À partir d'un ensemble d'apprentissage*

$$\{(\mathbf{x}_i, y_i)\}_{i=1}^n,$$

*le but est d'apprendre une fonction  $\hat{f}$  capable de bien prédire  $y$  sur de nouvelles observations.*

## SVR : Principe et Objectif

# Pourquoi la Régression à Vaste Marge ?

Les méthodes de régression classiques (ex. : régression linéaire) cherchent à **minimiser l'erreur quadratique globale** :

$$\sum_{i=1}^n (y_i - \hat{f}(\mathbf{x}_i))^2.$$

Mais ce critère :

- est **sensible aux valeurs aberrantes**,
- impose des pénalités fortes aux grandes erreurs,
- ne contrôle pas la **complexité du modèle**.

## Idée de la SVR

Ignorer les erreurs **petites** : on tolère une zone d'insensibilité de largeur  $\varepsilon$  autour de la prédiction.

*Toutes les erreurs de taille  $\leq \varepsilon$  sont considérées comme nulles.*

# Principe de la régression $\varepsilon$ -insensible

On définit un tube de largeur  $\varepsilon$  autour du modèle :

$$|y - f(\mathbf{x})| \leq \varepsilon.$$

## Interprétation :

- les points **dans le tube** ne sont pas pénalisés,
- seuls les points **en dehors du tube** comptent,
- la fonction doit rester **aussi plate que possible**.

### Idée intuitive

On autorise une erreur contrôlée (jusqu'à  $\varepsilon$ ) pour obtenir un modèle simple, robuste et peu sensible au bruit.

## Que cherche-t-on à optimiser ?

L'objectif est double :

- 1 Minimiser la **complexité du modèle** (mesurée par  $\|\beta\|^2$ ).
- 2 Limiter les **erreurs en dehors du tube**  $\varepsilon$ .

Pour cela, on introduit deux **variables de relâchement**  $\xi_i$  et  $\xi_i^*$ , qui mesurent de combien un point dépasse le tube :

- $\xi_i$  : dépassement **par au-dessus** (prédiction trop basse),
- $\xi_i^*$  : dépassement **par en-dessous** (prédiction trop haute).

Le problème primal devient :

$$\min_{\beta, b, \xi_i, \xi_i^*} \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*)$$

$$\text{s.c. } \begin{cases} y_i - \langle \beta, x_i \rangle - b \leq \varepsilon + \xi_i, \\ \langle \beta, x_i \rangle + b - y_i \leq \varepsilon + \xi_i^*, \\ \xi_i, \xi_i^* \geq 0. \end{cases}$$

## Interprétation des variables de relâchement

Dans la SVR, deux slacks sont nécessaires pour mesurer les dépassements du tube  $\varepsilon$  :

- **Dépassement par le haut** (prédition trop grande) :

$$\hat{y}_i - y_i > \varepsilon \quad \Rightarrow \quad \xi_i^* > 0.$$

- **Dépassement par le bas** (prédition trop petite) :

$$y_i - \hat{y}_i > \varepsilon \quad \Rightarrow \quad \xi_i > 0.$$

Les points :

- **dans le tube** :  $\xi_i = \xi_i^* = 0$ ,
- **sur les parois du tube** :  $\xi_i = \xi_i^* = 0$  (vecteurs de support marginaux),
- **en dehors du tube** :  $\xi_i > 0$  ou  $\xi_i^* > 0$ .

# Rôle du paramètre $C$

## Interprétation

- **Petit  $C$**  : modèle très plat, grande tolérance aux erreurs.
  - **Grand  $C$**  : modèle qui suit étroitement les données.
- 
- $C$  contrôle le compromis entre **largeur du tube** et **pénalisation des slacks** ( $\xi_i, \xi_i^*$ ).
  - Plus  $C$  est grand, plus on pénalise fortement les points en dehors du tube.

## Formulation duale

# Formulation lagrangienne

Les multiplicateurs de Lagrange sont :

$$\alpha_i, \alpha_i^* \geq 0 \quad (\text{contraintes du tube})$$

$$\eta_i, \eta_i^* \geq 0 \quad (\text{positivité des slacks})$$

Les contraintes sont réécrites sous la forme  $g_i \leq 0$  :

$$\begin{cases} y_i - \langle \beta, x_i \rangle - b - \varepsilon - \xi_i \leq 0, \\ \langle \beta, x_i \rangle + b - y_i - \varepsilon - \xi_i^* \leq 0, \\ -\xi_i \leq 0, \quad -\xi_i^* \leq 0. \end{cases}$$

Le Lagrangien est :

$$\begin{aligned} \mathcal{L} = & \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) + \sum_{i=1}^n \alpha_i (y_i - \langle \beta, x_i \rangle - b - \varepsilon - \xi_i) \\ & + \sum_{i=1}^n \alpha_i^* (\langle \beta, x_i \rangle + b - y_i - \varepsilon - \xi_i^*) - \sum_{i=1}^n \eta_i \xi_i - \sum_{i=1}^n \eta_i^* \xi_i^*. \end{aligned}$$

## Conditions d'optimalité

En annulant les dérivées :

$$\frac{\partial \mathcal{L}}{\partial \beta} = 0 \Rightarrow \beta = \sum_{i=1}^n (\alpha_i - \alpha_i^*) x_i$$

$$\frac{\partial \mathcal{L}}{\partial b} = 0 \Rightarrow \sum_{i=1}^n (\alpha_i - \alpha_i^*) = 0$$

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = C - \alpha_i - \eta_i = 0, \quad \frac{\partial \mathcal{L}}{\partial \xi_i^*} = C - \alpha_i^* - \eta_i^* = 0$$

Comme  $\eta_i, \eta_i^* \geq 0$  :

$$0 \leq \alpha_i, \alpha_i^* \leq C.$$

**Conclusion :** la solution dépend uniquement de  $\alpha_i, \alpha_i^*$ .

# Pourquoi passer au dual ?

## Intérêt majeur :

- Le problème dual dépend uniquement des **produits scalaires** :

$$\langle x_i, x_j \rangle.$$

- Cela permet d'introduire directement les **noyaux** :

$$\langle x_i, x_j \rangle \rightarrow K(x_i, x_j).$$

- La solution finale s'écrit en fonction des **vecteurs de support**.

## Conséquence

La SVR devient naturellement non linéaire grâce au **kernel trick**.

## Problème dual de la SVR

Le dual s'écrit :

$$\begin{aligned} \max_{\alpha_i, \alpha_i^*} W(\alpha, \alpha^*) &= -\frac{1}{2} \sum_{i,j} (\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*) \langle x_i, x_j \rangle \\ &\quad - \varepsilon \sum_i (\alpha_i + \alpha_i^*) + \sum_i y_i (\alpha_i - \alpha_i^*) \\ \text{s.c. } \sum_i (\alpha_i - \alpha_i^*) &= 0, \quad 0 \leq \alpha_i, \alpha_i^* \leq C. \end{aligned}$$

## Solution sous forme de vecteurs de support

La fonction estimée est :

$$\hat{f}(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \langle x_i, x \rangle + b.$$

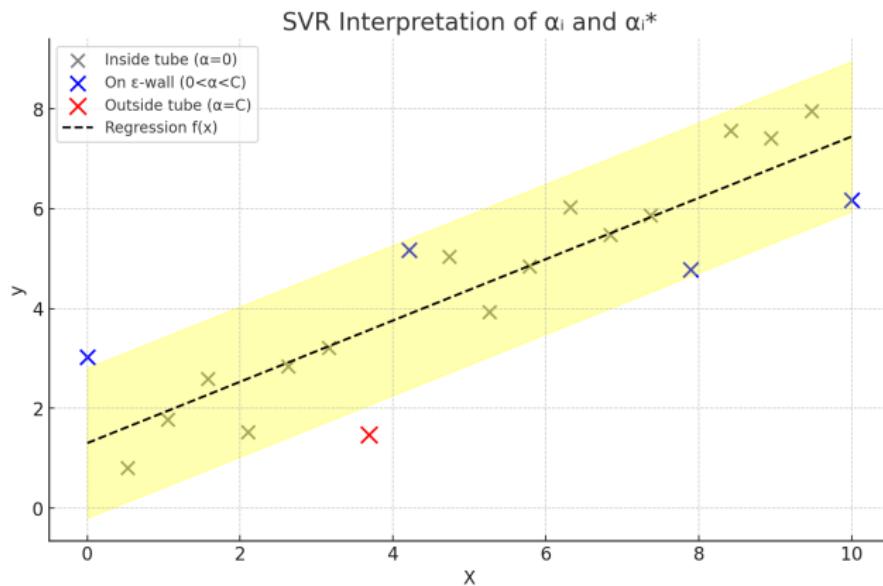
Les points utiles sont ceux pour lesquels :

$$|\alpha_i - \alpha_i^*| > 0.$$

Interprétation :

- **Dans le tube** :  $\xi_i = \xi_i^* = 0$  et  $\alpha_i = \alpha_i^* = 0 \Rightarrow$  pas vecteur de support.
- **Sur les parois** :  $0 < \alpha_i < C$  ou  $0 < \alpha_i^* < C \Rightarrow$  vecteurs de support marginaux.
- **En dehors du tube** :  $\alpha_i = C$  ou  $\alpha_i^* = C \Rightarrow$  vecteurs de support avec erreur.

# Solution sous forme de vecteurs de support



## Astuce du noyau

# Pourquoi utiliser un noyau ?

Le modèle linéaire de la SVR :

$$\hat{f}(x) = \langle \beta, x \rangle + b$$

ne permet de modéliser que des **relations linéaires**.

Dans de nombreux problèmes réels :

- la relation  $x \mapsto y$  est **non linéaire**,
- augmenter la dimension manuellement est coûteux,
- la régression linéaire (ou SVR linéaire) devient insuffisante.

## Idée clé

Transformer les données dans un espace de grande dimension où le problème **devient linéaire**.

But : rendre la SVR capable d'apprendre des frontières **non linéaires**.

# Interprétation géométrique

**Idée :** Appliquer une transformation :

$$x \longmapsto \varphi(x)$$

vers un espace de dimension élevée où les données deviennent plus facilement séparables.

**Exemple (idée) :**

$$x = (x_1, x_2) \quad \mapsto \quad \varphi(x) = (x_1, x_2, x_1^2, x_1 x_2, x_2^2).$$

Dans cet espace :

- le tube SVR devient un **tube linéaire**,
- le modèle devient une simple SVR linéaire,
- mais dans l'espace original, la fonction est **non linéaire**.

# Pourquoi le noyau est-il si puissant ?

Calculer explicitement  $\varphi(x)$  peut être :

- très coûteux (dimension énorme),
- voire infini (noyau RBF  $\Rightarrow$  espace de dimension infinie).

## Astuce du noyau

On ne calcule **jamais**  $\varphi(x)$ . On calcule directement :

$$K(x_i, x_j) = \langle \varphi(x_i), \varphi(x_j) \rangle.$$

## Conséquence :

- complexité très faible,
- expressivité très élevée,
- capacité à apprendre des relations très **non linéaires**.

## Astuce du noyau (Kernel Trick)

Dans le dual, les données apparaissent uniquement via :

$$\langle x_i, x_j \rangle.$$

### Définition d'un noyau

Un noyau calcule un **produit scalaire dans un espace transformé** :

$$K(x_i, x_j) = \langle \varphi(x_i), \varphi(x_j) \rangle,$$

sans jamais calculer explicitement la transformation  $\varphi$ .

On remplace :

$$\langle x_i, x_j \rangle \longrightarrow K(x_i, x_j)$$

où  $K$  peut être linéaire, polynomial, RBF, sigmoïdal...

## Modèle final avec noyau

$$\hat{f}(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) K(x_i, x) + b.$$

### Conclusion

Grâce au noyau, la SVR peut apprendre des fonctions **non linéaires** tout en restant un problème **linéaire dans l'espace transformé**.

## Résumé : SVR avec noyau en 4 étapes

- 1 Choisir un noyau  $K(x_i, x_j)$  (linéaire, polynomial, RBF, sigmoïdal...).
- 2 Résoudre le problème dual :

$$\max_{\alpha_i, \alpha_i^*} W(\alpha, \alpha^*)$$

sous

$$\sum_i (\alpha_i - \alpha_i^*) = 0, \quad 0 \leq \alpha_i, \alpha_i^* \leq C.$$

- 3 Calculer la fonction :

$$\hat{f}(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) K(x_i, x) + b.$$

- 4 Les seuls points utiles sont les **vecteurs de support** :

$$|\alpha_i - \alpha_i^*| > 0.$$

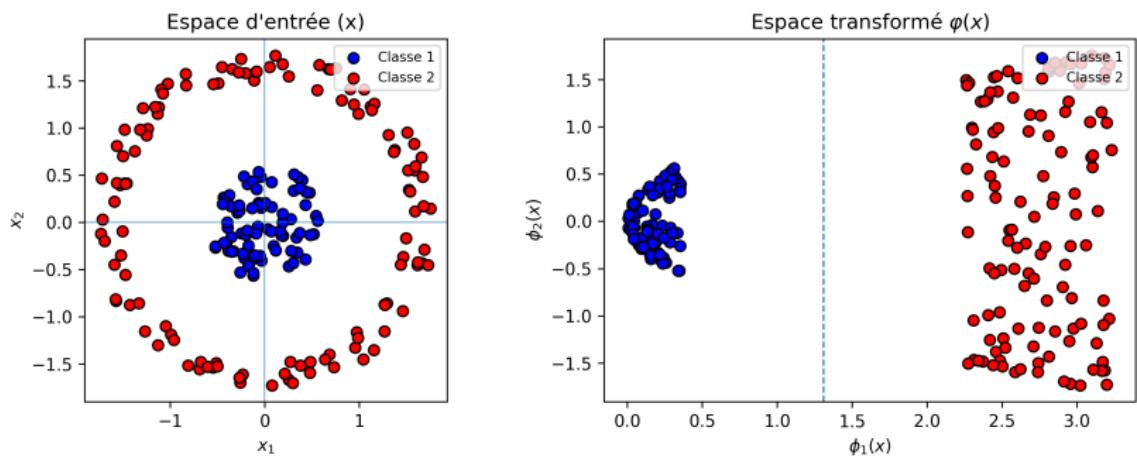
## Quels noyaux utiliser en pratique ?

- **Noyau linéaire** Simple, rapide, adapté si les données sont presque linéaires.
- **Noyau polynomial** Apprend des relations du type interactions, courbes douces.
- **Noyau RBF (Gaussian)** Le plus utilisé. Permet d'apprendre des relations très **non linéaires**. Ne nécessite pas de choisir un degré.
- **Noyau sigmoïdal** Proche des réseaux neuronaux. Rarement utilisé aujourd'hui.

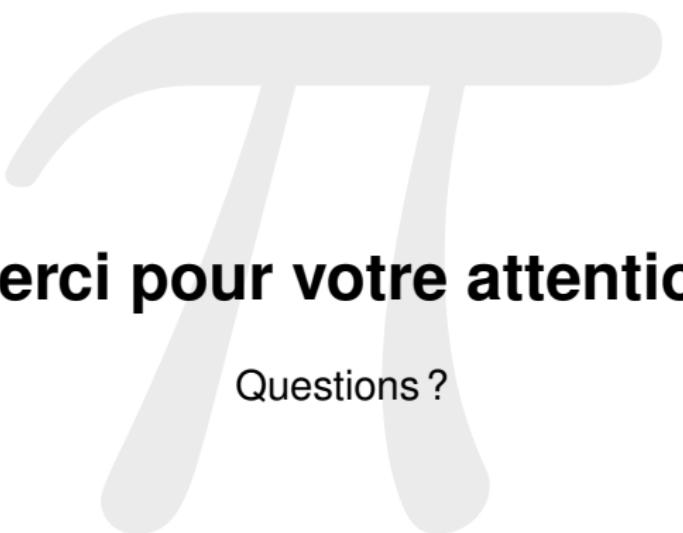
### Recommandation

En pratique : **RBF** est presque toujours le meilleur choix par défaut.

## Vision schématique du kernel trick



Dans l'espace d'origine : données non linéaires  $\Rightarrow$  **SVR linéaire impossible.**  
Après transformation implicite  $\varphi(x)$  : hyperplan + tube linéaire  $\Rightarrow$  **SVR linéaire possible.**



**Merci pour votre attention**

Questions ?